


/* elice */

양재 AI School 인공지능 캠프

Lecture 6

분류 (Classification)



박상기 선생님

수업 목표

- 1 ○ 분류 (Classification)의 의미를 이해한다

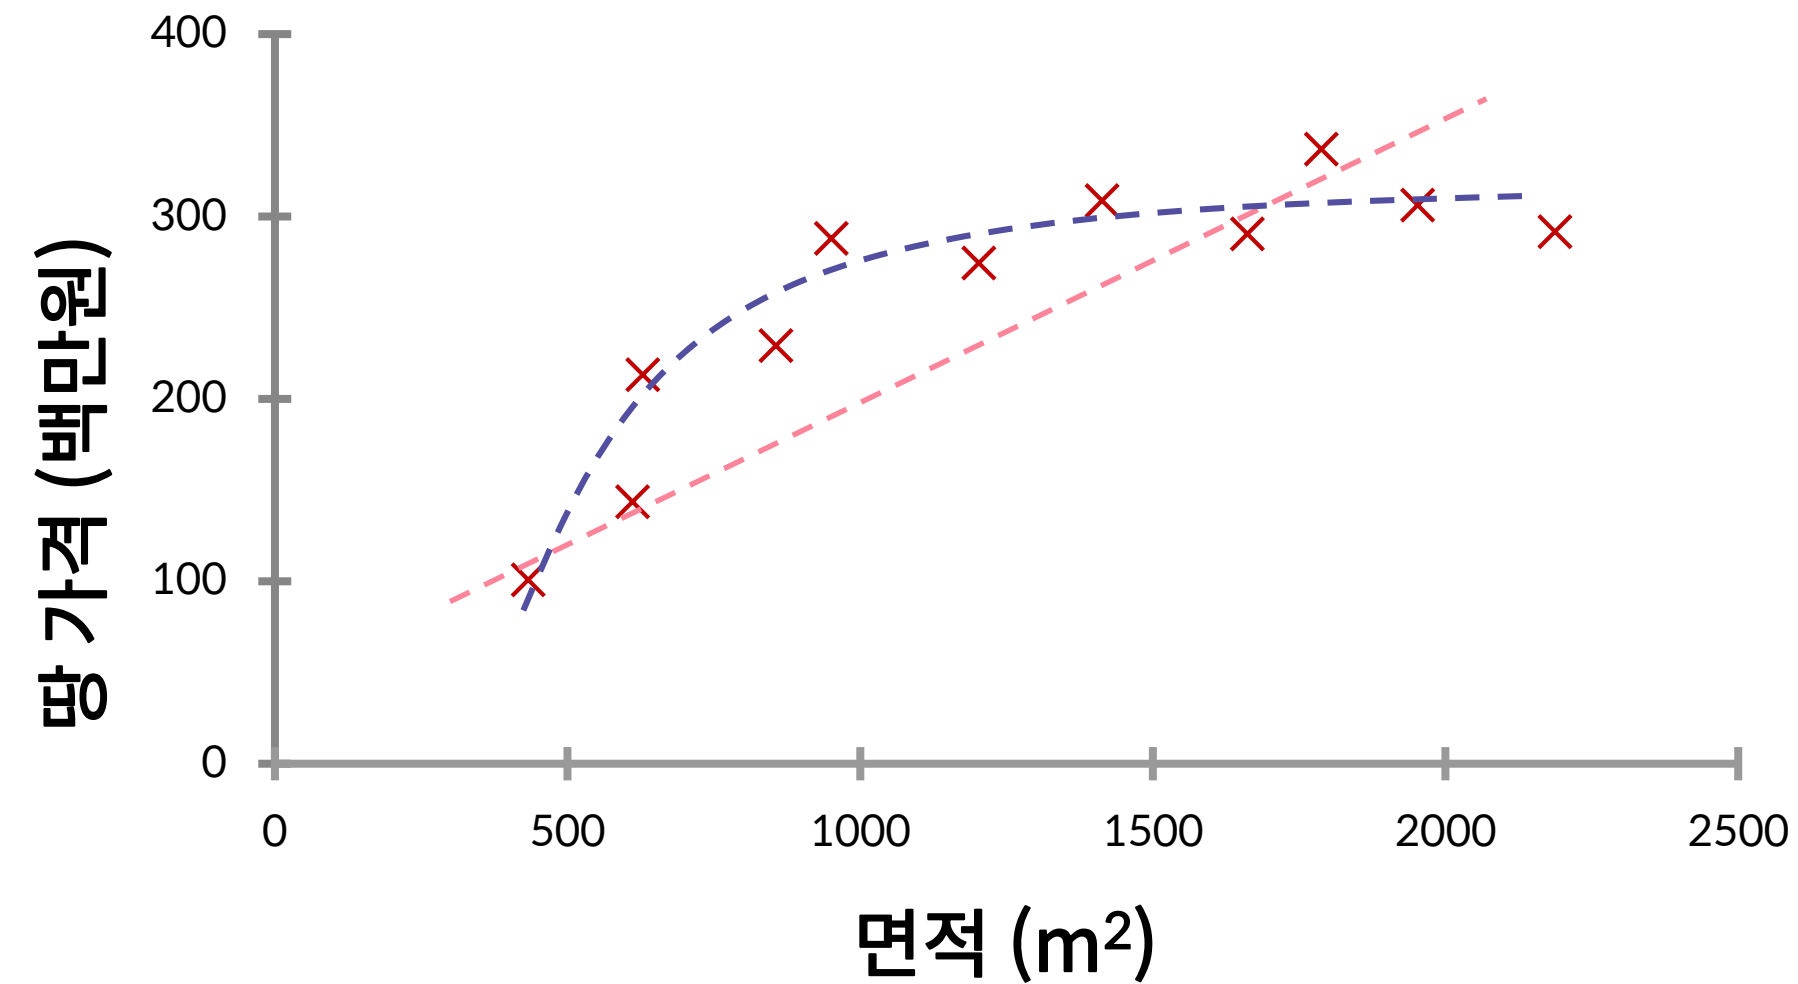
Classification의 특성과 알고리즘, 그리고 Regression과의 차이점을 알아봅시다.
- 2 ○ Classification의 다양한 방식을 알아본다

Logistic Regression, Softmax, Naïve Bayes, SVM 등의 분류 방식을 알아봅시다

Classification의 개념


Regression vs Classification

Regression



- 분포된 데이터를 **방정식 (Hypothesis)**을 통해 결과의 **값**을 예측


Supervised Learning



- **Classification** : 주어진 input이 어느 카테고리에 있는지 판별

Classification

- **Regression**이 결과값을 추정하는 방식이었다면,
Classification은 카테고리에 분류하는 방식



Linear regression은 **Classification**에 사용할 수 없다!

Classification

- Linear regression은 사용 불가능
- Classification은 0, 또는 1값만 가지는데, linear regression은 그 범위 이상의 값을 가질 수 있다.
- 0 또는 1 사이의 값만 내보내는 Hypothesis 함수가 필요


Logistic Regression

Logistic function을 사용한 분류

Logistic Regression


- 0~1 사이의 값만 내보내는 함수가 필요하다
- $0 \leq h(x) \leq 1$
- **Sigmoid (logistic) function**

$$h(x) = g(\boldsymbol{\theta}^T \mathbf{x}) = \frac{1}{1 + e^{-\boldsymbol{\theta}^T \mathbf{x}}}$$



Logistic Regression

$$h(x) = g(\boldsymbol{\theta}^T \mathbf{x}) = \frac{1}{1 + e^{-\boldsymbol{\theta}^T \mathbf{x}}}$$



$$\boldsymbol{\theta} = \begin{bmatrix} \theta_0 \\ \theta_1 \\ \dots \\ \theta_n \end{bmatrix}, \mathbf{x} = \begin{bmatrix} x_0 \\ x_1 \\ \dots \\ x_n \end{bmatrix}, \boldsymbol{\theta}^T \mathbf{x} = \theta_0 x_0 + \theta_1 x_1 + \dots + \theta_n x_n$$


Logistic Regression

- $h(x) = P(y = 1|x; \theta)$
- 주어진 input이 x 라는 값을 가질 때 1번 class에 들어갈 확률
- 1번 class일 확률과 0번 class일 확률의 합은 항상 1이 되어야 한다
- $P(y = 1|x; \theta) + P(y = 0|x; \theta) = 1$


Decision Boundary

- 언제 어떤 클래스에 넣어주어야 할까?
- Hypothesis function의 값 0.5를 기준으로 분류

- $y = \begin{cases} 1 & \text{if } \theta^T \mathbf{x} \geq 0 \\ 0 & \text{if } \theta^T \mathbf{x} < 0 \end{cases}$, where $h(x) = \frac{1}{1+e^{-\theta^T \mathbf{x}}}$



Decision Boundary




$$\begin{aligned} h(x) &= g(\theta_0 + \theta_1 x_1 + \theta_2 x_2) \\ &= g(-3 + x_1 + x_2) \\ &= \frac{1}{1 + e^{-(-3 + x_1 + x_2)}} \end{aligned}$$

$\theta^T x = -3 + x_1 + x_2 \geq 0$ 이면 $y = 1$ 로 예측하자

$h(x) = 0.5$ 이면 $\theta^T x = 0$

Non-Linear Decision Boundary



$$h(x) = g(\theta_0 + \theta_1 x_1 + \theta_2 x_2 + \theta_3 x_1^2 + \theta_4 x_2^2)$$



$$= g(-1 + x_1^2 + x_2^2)$$

$\theta^T \mathbf{x} = -1 + x_1^2 + x_2^2 \geq 0$ 이면 $y = 1$ 로 예측하자


$h(x) = 0.5$ 이면 $\theta^T \mathbf{x} = 0$

Cost Function

- θ parameter 값을 어떻게 정할까?
- Linear regression을 그대로 사용하면 non-convex
- Logistic 만의 cost function이 필요하다



Cost Function



$$\text{Cost}(h_{\theta}(x), y) = \begin{cases} -\log(h_{\theta}(x)) & \text{if } y = 1 \\ -\log(1 - h_{\theta}(x)) & \text{if } y = 0 \end{cases}$$

- $y = \begin{cases} 1 & \text{if } \boldsymbol{\theta}^T \mathbf{x} \geq 0 \\ 0 & \text{if } \boldsymbol{\theta}^T \mathbf{x} < 0 \end{cases} = \begin{cases} 1 & \text{if } h(x) \geq 0.5 \\ 0 & \text{if } h(x) < 0.5 \end{cases}$
- $y = 1$ 이고, $h(x) = 0$ 이면 잘못 분류하고 있다는 뜻 => **Penalty**

Cost Function

$$\text{Cost}(h_{\theta}(x), y) = \begin{cases} -\log(h_{\theta}(x)) & \text{if } y = 1 \\ -\log(1 - h_{\theta}(x)) & \text{if } y = 0 \end{cases}$$

$$\begin{aligned} J(\theta) &= \frac{1}{m} \sum_{i=1}^m \text{Cost}(h_{\theta}(x^{(i)}), y^{(i)}) \\ &= -\frac{1}{m} \left[\sum_{i=1}^m y^{(i)} \log h_{\theta}(x^{(i)}) + (1 - y^{(i)}) \log (1 - h_{\theta}(x^{(i)})) \right] \end{aligned}$$

Gradient Descent

$$J(\theta) = -\frac{1}{m} \left[\sum_{i=1}^m y^{(i)} \log h_{\theta}(x^{(i)}) + (1 - y^{(i)}) \log (1 - h_{\theta}(x^{(i)})) \right]$$


Repeat until convergence, do{

$$\theta_j := \theta_j - \alpha \left(\sum_{i=1}^m (h(x^{(i)}) - y^{(i)}) x_j^{(i)} \right), \text{ for all } \theta_j$$


}

$$\text{where, } h(x^{(i)}) = \frac{1}{1 + e^{-\theta^T x^{(i)}}}$$


[이론 6-1] Convex / non-Convex Cost Functions




Linear Regression Cost Function (convex)



Logistic Regression Cost Function (non-convex)




Logistic Regression Cost Function (convex)



Softmax Function

Logistic Regression의 binary class 분류에서
multi-class 분류로 확장

3개 이상의 카테고리?



- **A**인가 아닌가? -> **A** 선별
- **B**인가 아닌가? -> **B** 선별
- **C**인가 아닌가? -> **C** 선별
- 그럼 Cost function은?

Softmax Function

- $x = \begin{bmatrix} x_0 \\ x_1 \\ \dots \\ x_n \end{bmatrix}, \theta = \begin{bmatrix} \theta_0 \\ \theta_1 \\ \dots \\ \theta_n \end{bmatrix}$
- $x = \begin{bmatrix} x_0 \\ x_1 \\ \dots \\ x_n \end{bmatrix}, \theta = \begin{bmatrix} \theta_0 \\ \theta_1 \\ \dots \\ \theta_n \end{bmatrix}$
- $x = \begin{bmatrix} x_0 \\ x_1 \\ \dots \\ x_n \end{bmatrix}, \theta = \begin{bmatrix} \theta_0 \\ \theta_1 \\ \dots \\ \theta_n \end{bmatrix}$

$$\begin{bmatrix} \theta_{00} & \theta_{01} & \theta_{02} \\ \theta_{10} & \theta_{11} & \theta_{12} \\ \theta_{20} & \theta_{21} & \theta_{22} \end{bmatrix} * \begin{bmatrix} x_0 \\ x_1 \\ x_2 \end{bmatrix} = \begin{bmatrix} \hat{y}_0 \\ \hat{y}_1 \\ \hat{y}_2 \end{bmatrix}$$

y_i 에 Sigmoid를 적용!

Softmax Function

$$\begin{bmatrix} \hat{y}_0 \\ \hat{y}_1 \\ \hat{y}_2 \end{bmatrix} * [\text{sigmoid}(y_i) = \frac{e^{\hat{y}_i}}{\sum_i e^{\hat{y}_i}}] = \begin{bmatrix} 0.7 \\ 0.1 \\ 0.2 \end{bmatrix} \quad \text{A 그룹에 넣어주자!}$$

- Sigmoid의 결과값은 input이 각 카테고리에 속할 확률
- **결과 행렬의 모든 확률 값을 다 더하면 반드시 1**
- 가장 높은 확률값을 가지는 카테고리에 넣어준다
- Cost function으로는 **Cross-entropy** 사용

Softmax Function

- **One hot encoding:** 확률이 가장 높은 것만 1, 나머지는 0


- $h(x) = \begin{bmatrix} 0.7 \\ 0.1 \\ 0.2 \end{bmatrix} \Rightarrow \begin{bmatrix} 1 \\ 0 \\ 0 \end{bmatrix}$


- $\begin{bmatrix} x_0 \\ x_1 \\ x_2 \end{bmatrix} \Rightarrow \begin{bmatrix} \theta_{00} & \theta_{01} & \theta_{02} \\ \theta_{10} & \theta_{11} & \theta_{12} \\ \theta_{20} & \theta_{21} & \theta_{22} \end{bmatrix} * \begin{bmatrix} x_0 \\ x_1 \\ x_2 \end{bmatrix} = \begin{bmatrix} \hat{y}_0 \\ \hat{y}_1 \\ \hat{y}_2 \end{bmatrix} \Rightarrow \left[\text{sigmoid}(y_i) = \frac{e^{\hat{y}_i}}{\sum_i e^{\hat{y}_i}} \right] = \begin{bmatrix} 0.7 \\ 0.1 \\ 0.2 \end{bmatrix} \Rightarrow \begin{bmatrix} 1 \\ 0 \\ 0 \end{bmatrix}$

Softmax Function

- **Cross-entropy:** 두 변수들의 확률 분포가 얼마나 비슷한지 나타내는 척도

- $J(\theta) = -\frac{1}{m} \sum_{i=1}^m \left(y^{(i)} \ln \left(h(x^{(i)}) \right) \right), \text{ where } h(x^{(i)}) = \frac{1}{1 + e^{-\theta^T x^{(i)}}}$


$$\begin{bmatrix} 1 \\ 0 \\ 0 \end{bmatrix}$$



$$\begin{bmatrix} 0.7 \\ 0.1 \\ 0.2 \end{bmatrix}$$

Support Vector Machine (SVM)

비확률적 이진 선형분류모델


Support Vector Machine (SVM)

$$h(x) = g(\boldsymbol{\theta}^T \mathbf{x}) = \frac{1}{1 + e^{-\boldsymbol{\theta}^T \mathbf{x}}}$$



- $y = \begin{bmatrix} 1 \\ 0 \\ 0 \end{bmatrix}$ 에서,
 - $y = 1$ 이면, $h(x) \approx 1$, $\boldsymbol{\theta}^T \mathbf{x} \gg 0$ 일수록 좋고,
 - $y = 0$ 이면, $h(x) \approx 0$, $\boldsymbol{\theta}^T \mathbf{x} \ll 0$ 일수록 좋다

Support Vector Machine (SVM)





Logistic regression에서는...

$$\text{Cost}(h_{\theta}(x), y) = \begin{cases} -\log(h_{\theta}(x)) & \text{if } y = 1 \\ -\log(1 - h_{\theta}(x)) & \text{if } y = 0 \end{cases}$$

- $y = \begin{cases} 1 & \text{if } \theta^T x \geq 0 \\ 0 & \text{if } \theta^T x < 0 \end{cases} = \begin{cases} 1 & \text{if } h(x) \geq 0.5 \\ 0 & \text{if } h(x) < 0.5 \end{cases}$
- $y = 1$ 이고, $h(x) = 0$ 이면 잘못 분류하고 있다는 뜻 => **Penalty**

Support Vector Machine (SVM)

- **Hinge Function:** 1, -1 을 기준으로 값이 0이 되는 새로운 Cost function을 정의
- $y = 1$ 이면, $h(x) \approx 1, \theta^T x \gg 0$ 일수록 좋고,
- $y = 0$ 이면, $h(x) \approx 0, \theta^T x \ll 0$ 일수록 좋다



Cost Function of SVM

- Logistic regression:



$$\min_{\theta} \frac{1}{m} \left[\sum_{i=1}^m y^{(i)} \left(-\log h_{\theta}(x^{(i)}) \right) + (1 - y^{(i)}) \left(-\log(1 - h_{\theta}(x^{(i)})) \right) \right]$$

- **SVM:** cost의 평균대신 합을 사용


$$\min_{\theta} C \sum_{i=1}^m \left[y^{(i)} cost_1(\theta^T x^{(i)}) + (1 - y^{(i)}) cost_0(\theta^T x^{(i)}) \right]$$

Decision Boundary Margin

- $y = 1$ 이면, $\theta^T x \geq 1$ (*not* ≥ 0)
- $y = -1$ 이면, $\theta^T x \leq -1$ (*not* < 0)




Decision Boundary Margin



- Class를 분류하는 기준선에 여유를 둘 수 있다
- **Large Margin Classifier**



Decision Boundary Margin



- **Support Vector:** 결정
경계에 가장 가까운 데이터
- slack 변수를 이용해
어느정도 오차를
허용하기도 함


Kernel SVM

- Non-linear Decision Boundary
 - 데이터를 구분 짓는 '선'을 긋기 힘들다



Kernel SVM

- 데이터를 선형으로 구분할 수 있는 공간으로 재배치 한다
- 이때 데이터를 재배치 해주는 함수가 **Kernel**
- Polynomial, Sigmoid, Gaussian RBF ...



Naïve Bayes Classifier

통계적 기법을 이용한 클래스 규정 알고리즘

Bayes Rule

- Bayes 정리: $P(A|B) = \frac{P(A \cap B)}{P(B)} = \frac{P(B|A)P(A)}{P(B)}$
- $P(A|B)$: 사건 B가 발생했을 때, A도 같이 발생했을 확률

	비가 옴	비가 안옴	
맑은 날	2	8	10
흐린 날	5	5	10
	7	13	20

Bayes Rule

- $P(\text{비}|X|\text{맑}) = P(\text{맑}|\text{비}|X) * P(\text{비}|X) / P(\text{맑}) = 0.8$

	비가 옴	비가 안옴	
맑은 날	2	$P(\text{맑} \text{비} X)=8/13$	$P(\text{맑})=0.5$
흐린 날	5	5	10
	7	$P(\text{비} X)=0.65$	20

Naïve Bayes

- 각 특징들이 서로 영향을 미치지 않는다고 가정 (**독립적**)
- 만약 오늘 **맑고**, 바람이 **세고**, 기압이 **낮고**, 온도가 **낮다**면 비가 올 확률은?

	날씨		바람		기압		온도		
	맑음	흐림	셈	약함	높음	낮음	높음	낮음	계
비 올	2	6	6	2	8	0	5	3	8
비 안올	8	4	2	10	2	10	6	6	12
계	10	10	8	12	10	10	11	9	20

Naïve Bayes

$$\frac{P(\text{비}|\text{맑음}, \text{셈}, \text{기압낮}, \text{온도낮})}{P(\text{비}|\text{맑음}, \text{셈}, \text{기압낮}, \text{온도낮}) + P(\sim\text{비}|\text{맑음}, \text{셈}, \text{기압낮}, \text{온도낮})}$$

$$P(\text{비}|\text{맑음}, \text{셈}, \text{기압낮}, \text{온도낮}) =$$

$$P(\text{맑음}|\text{비})P(\text{셈}|\text{비})P(\text{기압낮}|\text{비})P(\text{온도낮}|\text{비})P(\text{비})$$

$$P(\sim\text{비}|\text{맑음}, \text{셈}, \text{기압낮}, \text{온도낮}) =$$

$$P(\text{맑음}|\sim\text{비})P(\text{셈}|\sim\text{비})P(\text{기압낮}|\sim\text{비})P(\text{온도낮}|\sim\text{비})P(\sim\text{비})$$

Naïve Bayes

$$\frac{P(\text{비}|\text{맑음, 썸, 기압낮, 온도낮})}{P(\text{비}|\text{맑음, 썸, 기압낮, 온도낮}) + P(\text{비안옴}|\text{맑음, 썸, 기압낮, 온도낮})} = \frac{0.0018}{0.0018 + 0.0278} = 0.0608 = 6.08\%$$

	날씨		바람		기압		온도		
	맑음	흐림	썸	약함	높음	낮음	높음	낮음	계
비 옴	2/8	6	6/8	2	6	2/8	5	3/8	8/20
비 안옴	8/12	4	2/12	10	2	10/12	6	6/12	12/20
계	10	10	8	12	10	10	11	9	20

Naïve Bayes

- 스팸 메일의 분류
 - 스팸인 메일과 정상적인 메일의 단어를 체크
 - 새로운 메일의 단어들에 대한 확률로 스팸메일을 구분

IDX	type	text
1	ham	Hope you are having a good week. Just checking in
2	ham	K..give back my thanks.
3	ham	Am also doing in cbe only. But have to pay.
4	spam	complimentary 4 STAR Ibiza Holiday or 10,000 cash needs your URGENT
5	spam	okmail: Dear Dave this is your final notice to collect your 4* Tenerife Holiday or
~		
5559	ham	Shall call now dear having food

idx	check	good	thanks	pay	~
1	1	1	0	0	~
2	0	0	1	1	
3	0	0	0	0	
~					

$P(\text{스팸}|\text{단어1, 단어2, 단어3 ...}) > P(\text{정상}|\text{단어1, 단어2, 단어3 ...})$ 이면 스팸

Naïve Bayes

- +) Multi-class 분류에서 쉽고 빠르게 예측 가능
- +) 각 특징들이 독립이라면 다른 분류 방식에 비해 결과가 좋고, 학습 데이터도 적게 필요
- -) 각 특징들이 독립이 아니라면 결과의 신뢰성 하락
- -) 학습 데이터에 없는 범주의 데이터가 들어오면 정상적인 예측 불가능

`/* elice */`

문의 및 연락처

academy.elice.io

contact@elice.io

facebook.com/elice.io

medium.com/elice